

Memoria Práctica 2

Aprendizaje Auto-supervisado de Representaciones Semánticas Distribucionales Estáticas FLPN

Ainhoa de Diego Silva
Rodrigo Romay Aba

Ejecución del proyecto.

Para ejecutar este proyecto, abriremos el editor de código a elección (en nuestro caso Visual Studio Code), y le haremos click en el icono de play para ejecutar el fichero elegido correspondiente a cada método, ya sea “cbow.py” o “skipgram.py”. Para que la ejecución funcione, debemos asegurarnos que los archivos de prueba (en formato .txt) estén en el directorio denominado “datasets”, así como que los archivos de palabras objetivo correspondientes se hallen en la carpeta “mats”.

Otra forma sería abrir la terminal predeterminada del equipo, movernos por comandos hasta la carpeta donde se encuentra el proyecto con los archivos de prueba e introducir “python cbow.py” o “python skipgram.py” según el método a comprobar.

Análisis de resultados y diferencias entre métodos.

Para el análisis de los resultados obtenidos en nuestra práctica, nos basaremos en las gráficas insertadas en el Apéndice, que nos son dadas por la propia ejecución de nuestro código. Estas gráficas se han generado para ambos algoritmos utilizando el archivo “game_of_thrones.txt”. Además, debemos destacar que utilizamos 64 como valor de las dimensiones de embedding, siendo esta cifra un valor intermedio para poder capturar relaciones semánticas de manera optimizada.

En CBOW, observamos una accuracy de apenas 0.12 (12%). Es importante no interpretar esto como un mal resultado. A diferencia de una clasificación binaria, CBOW intenta predecir una palabra específica entre todas las palabras del vocabulario. Estadísticamente, un acierto del 12% indica un aprendizaje sólido de la estructura sintáctica del lenguaje.

En cuanto a los valores de loss en la ejecución del CBOW, apreciamos una caída más dramática sobre todo en la primera etapa del entrenamiento seguida de una reducción constante del loss, pasando así desde valores inferiores a 7.5 hasta 5.65 aproximadamente. En cambio, en la métrica de validación de CBOW los datos se estabilizan un poco más (desde un valor un poco superior a 7 aproximado hasta un valor inferior que 6.5), sin llegar a reducir tanto el valor del loss como en entrenamiento. Esto se debe a que el modelo generaliza mejor con los

datos de entrenamiento sin alcanzar todavía el sobreajuste, ya que ambas curvas siguen en descenso.

Por otro lado, Skipgram presenta métricas radicalmente distintas: un accuracy de entrenamiento de 0.97 frente a un 0.76 en validación.

Aunque la diferencia pueda parecer abismal, la tarea de Skipgram es mucho más sencilla ya que se centra en predecir las palabras de contexto según la que hace de eje central y se generan mayor número de pares de entrenamiento. Esto facilita enormemente la tarea, lo que explica los valores de precisión tan altos.

Si pasamos al análisis del valor del loss en Skipgram, veremos una caída más pronunciada en entrenamiento (desde valores superiores a 1 aproximadamente hasta 0.15), pero una estabilización en validación (desde 0.58 hasta 0.30 aproximadamente). Esta diferencia entre entrenamiento y validación refleja un pequeño sobreajuste en las últimas etapas debido a la facilidad de aprender de Skip-gram. Es importante destacar la diferencia de valores del loss entre los dos algoritmos, ya que en Skipgram es mucho más reducido debido a la naturaleza de sus tareas explicada anteriormente, utilizando CBOW softmax y Skipgram negative sampling, dando éste una clasificación binaria mucha más sencilla con un valor del loss muy inferior.

Respecto a las gráficas representadas mediante tSNE, podemos apreciar de una manera clara como antes del entrenamiento de ambos modelos, las palabras se distribuyen de forma completamente aleatoria, destacando así una gran ausencia de estructura semántica.

Sin embargo, podemos apreciar una clara diferencia después de los entrenamientos.

- CBOW: agrupa palabras que son intercambiables. En los resultados, vemos que two se asocia con three (0.89) y man con woman (0.89). El modelo ha aprendido relaciones paradigmáticas: números con números, géneros con géneros. Visualmente, el t-SNE de CBOW muestra clústeres compactos y definidos por estas categorías.

Como ejemplos de agrupamientos de palabras generales que podemos apreciar en la gráfica tenemos: ["Man", "Woman", "Boy", "Girl"] y ["One", "Two", "Three", "Four"], los cuales se encuentran muy cercanos entre sí.

Respecto a ejemplos más específicos pertenecientes al vocabulario referente a "Juego de Tronos", podemos observar: personajes femeninos ["Arya", "Sansa"], personajes masculinos ["Jon", "Ned", "Tyrion", "Joffrey", "Robert"], palabras asociadas a vocabulario bélico ["Battle", "Fight", "Fought", "Die", "Died", "Powerful", "Ruled"],

“Kings”], así como vocabulario asociado con la casa Lannister [“Lannister”, “Cersei”, “Baratheon”].

- Skipgram. La gráfica resultante del entrenamiento de este algoritmo nos muestra claros ejemplos de agrupación semántica según el contexto, especificando de mejor forma las palabras propias del texto. Es decir, aprende que palabras van juntas en la narrativa.

Los ejemplos más claros se pueden visualizar como: [“Arya”, “Joffrey”, “Sansa”, “Stark”] como casa Stark, [“Lannister”, “Cersei”] como casa Lannister y [“Kingdom”, “Ambitious”] relacionado con el vocabulario de poder.

- Viendo ambas gráficas, el t-SNE de Skip-gram es mucho más disperso. Esto no es un error, sino que es el resultado de la fuerza de repulsión del Negative Sampling, que empuja a las palabras a ocupar todo el espacio vectorial para distinguirse de las muestras aleatorias, priorizando el contexto narrativo sobre la similitud gramatical.

Ventajas y desventajas de cada método de aprendizaje.

Por un lado, CBOW es un clasificador multiclase (1 entre todas las palabras de vocabulario). Por ello, un *accuracy* del 12% es un éxito estadístico, ya que predecir el término exacto es una tarea compleja. También tiende a agrupar palabras que pueden sustituirse entre sí (números con números, géneros con géneros), es más robusto frente al ruido y sobreajusta menos que Skip-gram y genera clústeres muy compactos y definidos por categorías gramaticales.

Por otro lado, Skip-gram es un clasificador binario (Si o No). Esto justifica su alto *accuracy* (97%) al ser una tarea mucho más sencilla. Además, tiende a agrupar palabras que coexisten en la misma escena narrativa (personajes con sus hogares o títulos), muestra una mayor tendencia a la memorización de contextos locales y presenta una mayor dispersión debido a la fuerza de repulsión del Negative Sampling, priorizando la distinción semántica sobre la agrupación por "clases"

Tras el experimento, concluimos que no existe un modelo superior, sino dos aproximaciones distintas al lenguaje:

1. CBOW es superior para capturar la sintaxis y categorías gramaticales, siendo más estable y resistente al sobreajuste. Es ideal si se busca un modelo lingüístico general.
2. Skip-gram es superior para capturar el contexto y las relaciones semánticas de la historia. A pesar de su tendencia al sobreajuste en corpus pequeños, es el único capaz de vincular conceptos narrativos complejos (como objetos a sus dueños o lugares a sus personajes).

En el contexto de Juego de Tronos, Skip-gram ofrece una representación más rica del universo literario, mientras que CBOW proporciona una estructura más limpia y organizada de las clases de palabras.

Apartado Opcional: CBOW con Text8.

A diferencia de los corpus de Harry Potter o Juego de Tronos, el entrenamiento sobre text8 presenta una accuracy de validación de 0.1743 (17.43%). En un vocabulario de un cuarto de millón de palabras, la probabilidad de acertar por puro azar es muy pequeña por lo que lograr este accuracy en una sola época demuestra una buena convergencia. El modelo no solo ha aprendido, sino que ha logrado generalizar estructuras lingüísticas universales de la Wikipedia eficientemente.

Los resultados demuestran que CBOW brilla al capturar relaciones de palabras que cumplen la misma función gramatical. Unos ejemplos (entre otros):



- La palabra three tiene como vecinos a four, five, six y seven con similitudes superiores al 0.86.
- spain se asocia con italy, france, poland y austria (similitudes > 0.90). El modelo entiende que son entidades equivalentes dentro de un contexto político y geográfico.
- Se observa un clúster con anarchism, socialism, capitalism y liberalism. CBOW identifica que estos términos son intercambiables en discusiones sociopolíticas.



El gráfico de t-SNE después del entrenamiento muestra una estructura de clústeres funcionales. Se aprecian claramente grupos separados para colores, países y conceptos abstractos. La dispersión es mucho menor que en los modelos anteriores, lo que confirma que el espacio vectorial se ha organizado de forma jerárquica.

La superioridad de los resultados obtenidos con text8 demuestra que el éxito de los modelos de representación de palabras depende directamente de la escala y la heterogeneidad del vocabulario. Mientras que los textos narrativos sufren de una escasez de datos que hacen que la red a sobreajustar, el volumen de la Wikipedia permite un aprendizaje muy bueno. Esta diversidad contextual permite al modelo CBOW recoger la esencia lógica de los conceptos, transformando la información en categorías precisas mediante una sola etapa de entrenamiento y demostrando que la abundancia de muestras es un factor crítico para alcanzar una generalización estable.


Apéndice.



Gráficas del CBOW.







Gráficas del Skipgram.





Gráficas del CBOW con Text8.



[illegible]